

Sensoriamento Espectral e Simulação de Ocupação de Espectro Utilizando Redes Neurais Artificiais

Luiz Renault Leite Rodrigues (luiz.rodrigues@dtel.inatel.br)

Instituto Nacional de Telecomunicações (INATEL) Santa Rita do Sapucaí, MG 37540-000

Resumo—Neste trabalho o uso de redes neurais artificiais foi empregado para tarefas de sensoriamento espectral e simulação de ocupação de espectro no contexto de rádios cognitivos. Uma variação da rede U-Net foi empregada na detecção de ocupação espectral e uma recente proposta de geração de datasets a partir de sinais de referência coletados do ar foi validada como adequada para a realização de simulações de ocupação espectral.¹

I. INTRODUÇÃO

A partir do surgimento do conceito de Rádio Cognitivo [1], tem sido investido grande esforço de pesquisa para viabilizar o uso por usuários secundários de faixas de frequências eventualmente ociosas, sem prejuízo do seu emprego pelos usuários licenciados em caráter primário.

O principal requisito para o uso compartilhado do espectro por um rádio cognitivo que opera em caráter secundário é, portanto, evitar interferência na operação do usuário primário. Com isso, torna-se fundamental para o rádio cognitivo secundário acompanhar a utilização de canais por outros usuários. Esta tarefa é realizada através do **sensoriamento espectral**.

Em áreas de aplicação sem grande exploração comercial como o setor de Segurança Pública, nota-se que muitas dos sistemas rádio utilizados são antigos e necessitam de atualização. Tem-se ainda como característica adicional a existência dos mais variados sistemas e padrões, adotados pelos diferentes órgãos existentes no país.

O rádio cognitivo se destaca neste contexto, podendo atender aos requisitos para modernização dos sistemas de telecomunicações. Um exemplo é o desenvolvimento de formas de onda de banda larga para comunicações militares em HF, com grande aplicabilidade no Rádio Definido por Software (RDS), projeto do Ministério da Defesa, e nas novas famílias de rádios desenvolvidas e fabricadas pela Indústria de Material Bélico do Brasil - IMBEL, vistos na FIG. 1.




Figura 1. RDS Defesa (a), IMBEL TRC-1193V (b) TRC-1122 (c) e TPP-1400 (d).

O desenvolvimento das aplicações de software que rodam nestes rádios, chamadas Formas de Onda (FO), é um

processo complexo e custoso, necessitando muitas vezes de centenas ou milhares de horas de trabalho para validação das implementações. Outra dificuldade observada é a escassa fonte de dados e de modelos de ocupação espectral, principalmente relacionado a aplicações mais restritas como as militares e de segurança pública. Com isso, torna-se extremamente relevante a capacidade de simulação de tais situações utilizando modelos com parâmetros ajustados a partir de dados coletados experimentalmente.

A abordagem clássica para o sensoriamento espectral e simulação de sistemas de comunicações baseia-se na abordagem estocástica [2], com diversas limitações.

Recentemente o uso de Redes Neurais Artificiais (RNA) tem crescido, se popularizado bastante e ganhado as mídias, como por exemplo as aplicações ChatGPT e *Stable Diffusion* [3]. Tais ferramentas permitem a geração de imagens computadorizadas com elevado grau de realidade a partir de descrições textuais. Outras aplicações tem utilizado conceitos similares para a modelagem e síntese de dados no domínio do tempo, tendo como relevante exemplo a ferramenta TimeGPT [4], que permite a modelagem e predição de séries temporais usando RNA.

Algumas das vantagens do emprego de RNA são: capacidade de modelar complexidades não lineares, geração de dados realísticos, extrapolação em novos domínios, transferência de conhecimento / aprendizado, adaptabilidade a mudanças temporais, maior acurácia e eficiência em previsões e capacidade de lidar com grandes dados.

Dessa forma, cresce de importância a investigação de novas aplicações de RNA como substituição às abordagens clássicas para a solução de problemas associados ao sensoriamento espectral e simulação de sistemas de comunicações.

Assim, neste trabalho foi realizada a pesquisa e experimentações sobre o emprego de Redes Neurais Artificiais e Aprendizado de Máquina para a modelagem de uso do espectro eletromagnético para a partir dela realizar a simulação da ocupação espectral para o uso no desenvolvimento de Formas de Onda.

II. TRABALHOS RELACIONADOS

A tecnologia associada a rádios cognitivos já vem sendo pesquisada há mais de duas décadas e evoluiu bastante nos últimos anos. Para ajudar pesquisadores a se situarem nos avanços obtidos na temática sensoriamento espectral, [2] trás um resumo das principais técnicas e as classifica de acordo com a FIG. 2.

Tais técnicas são divididas principalmente em sensoriamento de banda estreita, ou *narrowband sensing*, e senso-

¹https://github.com/luizrenault/tp558/tree/main/projeto_final

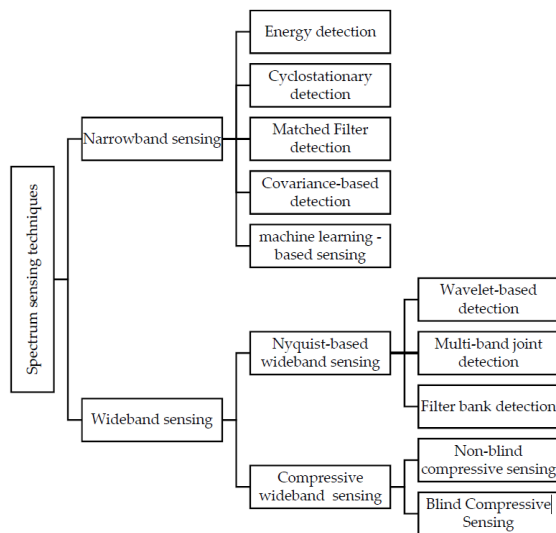


Figura 2. Classificação de técnicas de sensoriamento espectral [2].

riamento de banda larga, ou *wideband sensing*. O primeiro consiste na análise de um único canal de radiofrequência, enquanto o segundo analisa um conjunto de canais.

Dentre os métodos empregados para o sensoriamento de banda estreita estão o de detecção de energia, detecção ciclo-estacionária, sensoriamento com filtro casado, detecção baseada em covariância, e sensoriamento baseado em aprendizado de máquina, este último o de interesse deste trabalho.

O sensoriamento de banda larga pode ser subdividido em outras duas sub-categorias: baseada em Nyquist e compressiva. Exemplos de métodos da primeira sub-categoria são a detecção baseada em *Wavelet*, a detecção conjunta multi-banda e a detecção empregando bancos de filtros. Dentre os métodos compressivos estão os de sensoriamento cegos e os não-cegos, classificados de acordo com o a necessidade de conhecimento *a priori* da esparsidade dos canais sensoreados.

Detalhes sobre cada um destes métodos podem ser encontrados em [2] e suas referências. Dentre os onze métodos que utilizam aprendizado de máquina citados na publicação, nenhum deles cita ser capaz de gerar amostras realistas de ocupação espectral de banda estreita ou larga para uso em simulações de sistemas de rádios cognitivos, possuindo como foco principal a detecção (cooperativa ou individual) [5] da ocupação ou de ataques cibernéticos relacionados ao sensoriamento espectral.

Em [6] é mostrado o emprego de Modelos de Markov Escondidos Não Estacionários (NS-HMM) e Modelos Bivariados de Markov Escondidos (HBMM) na detecção e predição de ocupação espectral aplicados a dados reais obtidos durante as Olimpíadas e Paraolimpíadas Rio 2016. Tais modelos, após terem seus parâmetros estimados a partir de uma sequência de treinamento ou emprego adaptativo servem não só para estimar em tempo real a ocupação do espectro em banda estreita e prever a duração do estado de ocupação dado o estado atual, como também para produzir amostras simuladas com características estatísticas similares às dos dados reais

modelados. Além disso, seu uso é estendido para sensoria-mento de banda larga aplicando o modelo em múltiplos canais, obtendo bom desempenho ao óbice do aumento considerável do custo computacional.




Figura 3. Resultado do emprego de modelos NS-HMM em simulação de ocupação secundária de canais de RF [6].

A figura 3 mostra o resultado da simulação do uso secundário de canais de RF usando o modelo NS-HMM para detecção e predição do uso do espectro, onde são indicados os eventos de colisão, quando o usuário secundário transmite durante uma ocupação do canal pelo usuário primário, de sucesso, quando o usuário secundário transmite com o canal livre, de perda de oportunidades de transmissão e os períodos corretamente preditos como canal ocupado.

A extensão da aplicação dos NS-HMM e HBMM para sensoriamento espectral de banda larga, apesar de eficaz é ineficiente no sentido de que cada modelo é aplicado individualmente a um canal, não fazendo uso por exemplo de informações da relação estatística do uso de canais adjacentes. Além disso, o custo computacional é multiplicado pelo número de canais sensorizados, tornando-se não prático para diversas aplicações embarcadas de tempo real.

O uso de redes neurais generativas (RNG) para melhoria de modelos baseados em Modelos de Markov Escondidos pode ser encontrado em [7].

Redes neurais generativas funcionam, de uma forma bastante resumida, usando modelos de RNA para através de treinamento prévio aprender uma distribuição estatística latente presente em dados de referência, condicionados a características destes dados, e após, apresentadas características escolhidas, gerar outros dados realistas de acordo com as distribuições aprendidas.

Recentemente, novas arquiteturas de RNA e o aumento da capacidade computacional aplicada ao processamento de RNA popularizaram bastante o emprego de redes neurais generativas em aplicações como síntese de imagens realistas, geração de textos coerentes, geração de fala replicando vozes reais, e diversas outras. Dentre as arquiteturas de RNG destacam-se as Redes Generativas Adversárias [8], [9], os Auto Codificadores Variacionais (VAE) [10] e as baseadas em Modelos de Difusão (DM) [11]–[13]. Detalhes das arquiteturas e de implementação podem ser vistos em suas respectivas publicações.

De particular interesse nesta proposta, as redes baseadas em Modelos de Difusão possuem este nome pois baseiam-se no

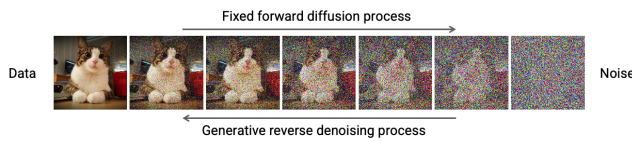


Figura 4. Ilustração do princípio de funcionamento das RNG baseada em Modelos de Difusão [14].

fenômeno físico da difusão, onde ruído é adicionado a um conjunto de dados de interesse, gerando amostras dos dados ruidosas, como se o próprio ruído fosse difundido. Durante o treinamento da rede, "observando" o processo gradual de difusão até a completa corrupção dos dados originais, a rede é capaz de "aprender" como realizar o processo inverso e estimar dados puros a partir de amostras ruidosas. Isso faz com que a rede incorpore uma distribuição estatística que representa o universo de dados apresentados no treinamento e ao receber uma amostra de ruído puro, realiza o processo gradual de eliminação do ruído até gerar uma amostra de dados que represente esta estatística.

Uma aplicação comum dos Modelos de Difusão é a geração de imagens realistas. Um exemplo do processo reverso difusão e geração de imagem pode ser visto na figura 4. O dado puro é a imagem do gato à esquerda e o dado completamente corrompido é a imagem da direita, apenas com ruído. O processo de difusão direta é indicado da esquerda para a direita, enquanto o processo de geração é indicado pela seta da direita para a esquerda. Mais detalhes desta arquitetura e seu funcionamento podem ser obtidos em [11].

Uma característica interessante dos Modelos de Difusão é que sua implementação é baseada em um outro modelo (Rede em U ou U-Net) empregado com destaque na segmentação e classificação semântica de dados ou imagens. Detalhes do modelo U-Net são descritos em [15], e a sua adaptação para uma rede generativa em [11].

Recentemente, bons resultados na classificação semântica de ocupação espectral empregando RNA baseada em U-Net foram obtidos em [16]. Este trabalho apresenta uma nova técnica para a classificação semântica com baixa latência, ao utilizar amostras I/Q obtidas do *front-end* de RF de rádios definidos por software, convertidas para o domínio da frequência, como entrada de uma rede neural U-Net modificada para uma dimensão para classificação ponto a ponto de uma linha de espectrograma. Outra contribuição deste trabalho se dá no sentido de propor uma nova metodologia para gerar um conjunto de amostras de treinamento rotuladas a partir da combinação com deslocamento de tempo e frequência de amostras I/Q de sinais de referência que fazem parte de um banco de sinais.

Ressalta-se que os trabalhos citados acima não representam todo o conjunto de métodos e técnicas relacionadas ao sensoriamento espectral ou a redes neurais generativas, mas o mínimo suficiente para o encadeamento das seções




Figura 5. Exemplo de espectrograma obtido por um rádio definido por software [17].

subsequentes, onde será apresentado o problema investigado, descritas a hipótese levantada para a solução deste problema, a metodologia utilizada para testar se a solução é eficaz e os resultados obtidos.

III. DESCRIÇÃO DO PROBLEMA

O problema tratado neste projeto é o sensoriamento espectral de banda larga com o objetivo de detectar o uso do espectro de radiofrequência (sub-problema i), realizar previsões sobre o uso futuro baseado no estado presente e passado (sub-problema ii), e a geração (simulação) de amostras de ocupação espectral utilizando um modelo treinado empregando amostras reais de uso do espectro que representem estatisticamente estes dados (sub-problema iii).

A figura 5 mostra a tela de uma aplicação baseada em rádio definido por software (SDR) disponível publicamente na internet, onde é possível visualizar o espectrograma de um sinal de radiofrequência capturado por uma estação localizada na cidade de Brasília-DF. O eixo horizontal representa frequências entre 23 MHz (à esquerda) e 30 MHz (à direita), enquanto o eixo vertical representa o tempo, sendo as amostras mais recentes as superiores, e as amostras inferiores as capturas dezenas de segundos antes. A codificação de cores da imagem representa a magnitude do sinal recebido, com potências baixas representada pela cor preta e azul escuro, médias pela ciano, até as mais elevadas pela coloração vermelha.

Dessa forma, pode-se concluir que há usuários utilizando o espectro nos instantes em que a cor dos pixels se difere da cor de fundo (azul ou preto).

Assim, para fazer o uso secundário ou oportunista do espectro, um rádio cognitivo deveria apenas transmitir nos casos em que não há outros usuários transmitindo, de forma a evitar infringir ou sofrer interferências.

Para tal, é necessário que o rádio cognitivo (RC) possa inferir sobre o estado de ocupação de uma determinada faixa

de frequência e sobre o tempo que esta faixa ficará disponível para seu uso. Esta atividade torna-se extremamente difícil caso o RC não possua informações prévias sobre como os outros usuários utilizam o espectro, o que é muito comum em aplicações práticas.

Além disso, torna-se fundamental para o desenvolvimento de aplicações para rádios cognitivos a capacidade de simular ambientes realistas produzindo cenários similares aos vistos na figura, no qual algoritmos cognitivos possam ser testados.

O diagrama de blocos da FIG. 6 ilustra processo do sensoriamento e detecção da presença do usuário primário. O sinal recebido $r(t)$ corresponde ao sinal transmitido por um sistema primário, alterado pelo canal e pelo ruído aditivo $n(t)$.




Figura 6. Diagrama de blocos do processo de sensoriamento espectral.

Nos algoritmos de detecção de energia para sensoriamento de banda estreita, a modelagem estatística da ocupação do canal compreende a definição de duas hipóteses dadas por:

$$r(t) = \begin{cases} n(t), & \text{Hipótese } H_1: \text{não há outro sinal} \\ p(t) + n(t), & \text{Hipótese } H_2: \text{há outro sinal.} \end{cases}$$

Com isso, define-se o **estado de ocupação** do canal s , onde $s = 1$ significa que a primeira hipótese é verdadeira e não há ocupação do canal, assim como $s = 2$ indica a ocupação do canal pelo usuário primário².

No caso do sensoriamento de banda larga, como na figura 5, $r(t)$ será substituído por $r(t, f)$ onde f é a frequência.

Na etapa de sensoriamento são realizadas as operações de recepção, filtragem, seleção de faixa ou canal, amostragem e conversão analógica digital. Os sinais digitalizados, normalmente expressos pelas suas componentes em fase e quadratura (I e Q) em banda base, podem ser pré-processados antes de serem apresentados ao detector, dando origem às estatísticas utilizadas no processo de detecção.

Dessa forma, os dados referência para os modelos podem ser repassados tanto no domínio do tempo, através das amostras complexas I e Q, no domínio da frequência, obtidos através da Transformada de Fourier do sinal, de representações estatísticas do sinal ou qualquer outra transformação do sinal capturado.

As saídas do modelo poderão ser de qualquer formato que represente os estados de ocupação definidos e / ou o sinal estimado no domínio do tempo, da frequência, ou qualquer transformação que solucione os sub-problemas i, ii ou iii.

O objetivo final do emprego do modelo é realizar a predição da ocupação espectral para executar uma transmissão (simulada) oportunista de maneira que não haja interferência entre o transmissor cognitivo e os demais usuários.

² Apesar do processo de detecção estar exemplificado com apenas 2 estados, um número maior de estados pode ser utilizado.

A. Solução proposta

Propõe-se inicialmente utilizar redes neurais generativas para aprenderem a distribuição latente da ocupação espectral em uma determinada faixa do espectro de radiofrequência e ser capaz de inferir sobre a ocupação e gerar amostras realistas da ocupação espectral para fins de simulação. Entretanto, a técnica de geração de amostras apresentada em [16] é citada como bastante eficaz para a simulação da ocupação espectral e é melhor candidata para a solução do sub-problema iii.

Paralelamente, o emprego de U-Net para detecção da ocupação espectral através da classificação semântica destaca-se como candidato a substituto das métricas de detecção de energia, detecção cicloestacionária, com filtro casado ou baseada em covariância, para a solução do sub-problema i.

Com isso, informação da detecção do uso do espectro obtida pela U-Net pode ser utilizada em conjunto com os modelos HMM para a predição de uso do espectro, resolvendo o sub-problema ii.

IV. METODOLOGIA

Os modelos investigados foram aplicados de maneira que os resultados produzidos pudessem ser expressos como na figura 3, permitindo a comparação de desempenho entre os modelos investigados baseados em RNG e o referenciado naquela publicação.

Para isso, foram utilizados os mesmos dados capturados em [6],

A investigação da solução proposta abrangue também:

- 1) Obtenção de implementações de referência das arquiteturas de RNA a serem empregadas;
- 2) Validação das implementações utilizando dados de referência que permitam a comprovação do funcionamento do modelo;
- 3) Tratamento dos sinais capturados em [6] para geração de dados de referência para aplicação dos modelos de RNA;
- 4) Complementação manual dos dados tratados para produzir uma classificação de referência para a ocupação do espectro;
- 5) Separação dos dados tratados e da classificação de referência em dois grupos: de treinamento e de avaliação;
- 6) Utilização dos dados tratados e da classificação de referência reservada para treinamento para treinar os modelos de RNA;
- 7) Aplicação das RNA nos dados de avaliação e gerar as métricas de desempenho;
- 8) Análise das métricas de desempenho;

A. Modelos utilizados

1) *Classificador Semântico Espectral Como Detector de Uso do Espectro*: A detecção de uso do espectro foi realizada empregando RNA com a topologia proposta por [16] e mostrada na figura 7. Trata-se de uma rede U-Net modificada para receber amostras de uma dimensão em oposição às imagens de duas dimensões, normalmente empregadas nas aplicações

de visão computacional, e conectada em série com um bloco não local.




Figura 7. Topologia de rede baseada em U-Net 1D com bloco não local [16].

As redes U-Net caracterizam-se por uma estrutura semi-simétrica formada por 3 partes principais: o codificador, o gargalo e o decodificador. O codificador é formado por camadas convolucionais de múltiplos blocos, cada um com múltiplos filtros conectados por blocos de sub-amostragem, normalmente do tipo Max-Pooling. O objetivo do codificador é extrair uma grande quantidade de mapas de características das amostras de entrada ao mesmo tempo que reduz a sua resolução espacial. Isso permite que tais características sejam levantadas e associadas em múltiplas escalas, reduzindo a informação de posição, porém aumentando o conteúdo semântico.

O gargalo é composto por blocos convolucionais conectados em série e possui como principal função a seleção das características mais importantes, generalizando o aprendizado, visando evitar o problema de super ajustagem do modelo em relação aos dados de treinamento.

O decodificador é formado por camadas compostas por blocos convolucionais intercalados com blocos de superamostragem e tem como objetivo recuperar a informação espacial combinando as características de alta resolução extraídas pelo codificador através das *skip connections* e as selecionadas pelo gargalo.

A topologia da rede U-Net conforme proposta originalmente em [15] pode ser vista na figura 8.

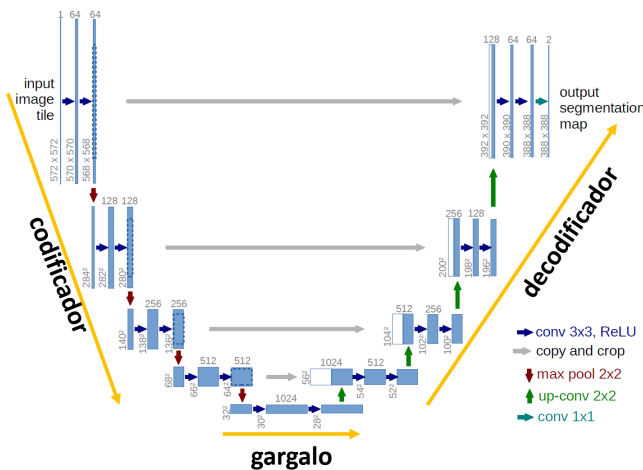


Figura 8. Topologia da Rede U-Net conforme proposta originalmente em [15].

Para aplicação na classificação semântica espectral, a topologia da rede U-Net foi modificada substituindo os filtros 3x3 originais por filtros 1x3, permitindo a entrada de amostras de uma dimensão. O codificador e decodificador são compostos por 5 camadas de dois blocos convolucionais com os filtros 1x3 seguidos de normalização por lote e ativação ReLU. Uma camada max-pooling 1x2 é usada para a redução da resolução espacial entre cada camada do codificador. Assim como na implementação original, foram mantidas as profundidades dos mapas de características de 64, 128, 256, 512 e 1024 para o codificador e a ordem inversa para o decodificador.

O bloco não local foi inserido para contornar a característica das redes convolucionais de processar grupos de características localmente, o que dificulta capturar informações distantes espacialmente. Nesta implementação foi optado por conectar este bloco na saída da U-Net de forma a integrar um processo de auto-atenção. Isso permite combinar características distantes espacialmente para melhorar o desempenho da classificação [16].

A convolução 1x1 na última camada foi colocada para que seja gerado um mapa de segmentação binário para cada uma das classes, visando permitir a classificação de sinais sobrepostos no domínio da frequência.

Com isso, a detecção de uso do espectro pode ser realizada verificando a presença de qualquer classe diferente do ruído de fundo.

2) *Gerador de Amostras de Treinamento como Simulador de Ocupação Espectral*: Uma das principais contribuições presentes em [16] é a proposta de uma nova metodologia para geração de amostras rotuladas de ocupação espectral para contornar o problema da escassez e da dificuldade de obtenção e rotulação de sinais capturados do ar. O método proposto baseia-se na costura de sinais de referência individuais para formar conjuntos de dados diversificados, de banda larga, e de longa duração.

Os sinais de referência podem ser sintetizados a partir dos diferentes padrões de sistemas de comunicações ou de capturados do ar em condições controladas que permitam seu rotulamento. A figura 9 mostra o pré-processamento necessário para preparar os sinais capturados para serem utilizados como sinais de referência. Adicionalmente, é colocada a condição de que durante a captura, não existam sinais sobrepostos que não possam ser eliminados da amostra coletada.

O processo de preparação consistem em filtrar as amostras I/Q capturadas, delimitando no espectro e eliminar os períodos de silêncio antes e depois do sinal, delimitando no tempo, de maneira que persista apenas o sinal de interesse. Em seguida é realizada a centralização do sinal com a conversão para banda base e a sub-amostragem de maneira a que as amostras resultantes tenham taxa de amostragem que comporte exatamente o sinal de referência na etapa denominada *pruning*, visando a redução do número de amostras necessário para armazenar o sinal. As informações do tipo de sinal (rótulo) e largura de banda (taxa de amostragem) são então armazenadas junto com as amostras em um banco de sinais.

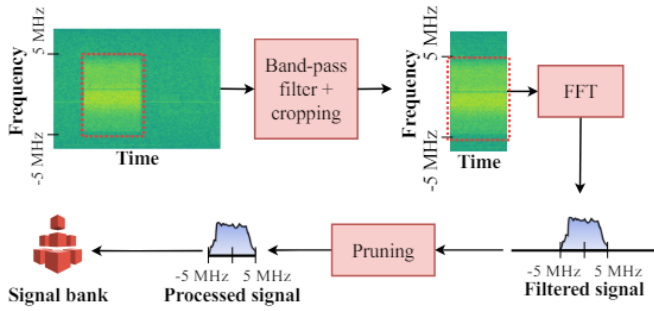


Figura 9. Pré-processamento de sinais gravados para compor os sinais de referência [16].

Conforme a proposta para a geração das amostras do *dataset*, alguns dados devem ser definidos. Entre eles destacam-se a largura de banda do sinal a ser gerado, o número de classes existentes no banco de sinais, o número máximo permitido de classes presentes em um instante de tempo e a probabilidade do espectro inteiro não estar ocupado.

Primeiro é sorteado se aquela amostra de tempo conterá algum sinal, de acordo com a probabilidade estabelecida. Para o caso em que a amostra conterá sinal, é realizado um sorteio do número de sinais que estarão presentes, seguindo uma distribuição uniforme de 1 até o número de classes presentes no banco de sinais. Para o número sorteado, são sorteadas também seguindo uma distribuição uniforme as frequências centrais em que os sinais se apresentarão, e as classes que serão inseridas na amostra.

Então, o sinal de referência é retirado do banco de sinais, deslocado em frequência e somado aos demais de maneira a produzir a sequência de amostras I/Q relacionadas com a ocupação espectral sorteada. Em seguida as informações de rótulos são criadas a partir dos dados de largura de banda e identificação da classe que acompanham as amostras de referência. O resultado é finalmente agregado ao *dataset*. A figura 10 ilustra este processo.

É fácil perceber que manipulando as distribuições de probabilidades envolvidas no processo de geração das amostras pode-se controlar as diversas características do *dataset* sintetizado, dando bastante flexibilidade para o emprego desta técnica na simulação de ocupação espectral.

V. RESULTADOS OBTIDOS

As simulações foram realizadas utilizando as bibliotecas de aprendizado de máquina em linguagem Python no ambiente de desenvolvimento Google Colab. As implementações foram realizadas através da adaptação para este ambiente do código fonte fornecido por [16], originalmente desenvolvido para rodar no modo *stand alone*, em linha de comando.

O banco de sinais de referência, fornecido em conjunto com o código foi utilizado para validar a implementação e para realização das simulações.

Os processos de geração de *dataset*, treinamento da rede e teste de classificação foram reproduzidos obtendo resultados consistentes com os apresentados em [16].

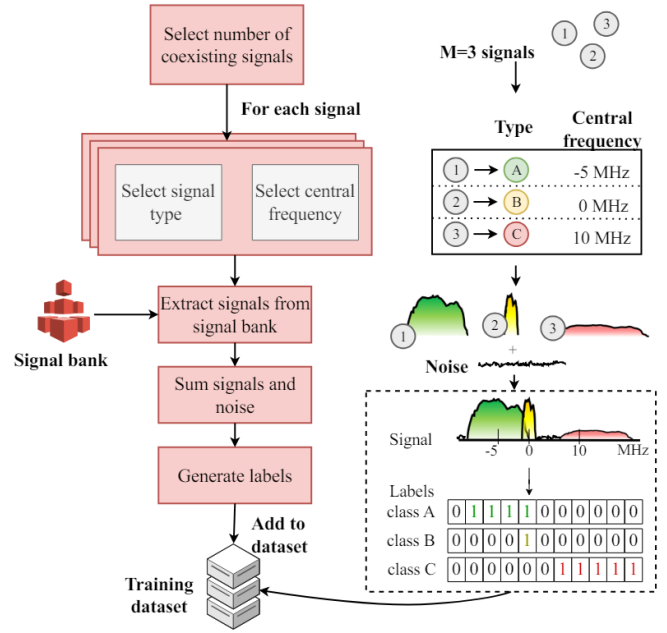


Figura 10. Geração de de uma amostra de treinamento [16]

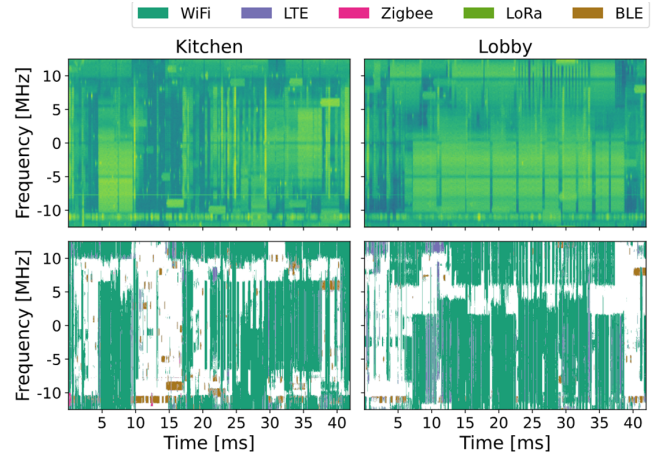


Figura 11. Resultados apresnetados em [16].




Figura 12. Latência na inferência para diferentes modelos e larguras de banda [16].

Como os códigos fornecidos não apresentavam métodos para visualização dos dados, grande esforço foi envidado para a complementação desta funcionalidade, não tendo sido concluído até o momento de submissão deste relatório.

VI. CONCLUSÃO E SUGESTÃO PARA TRABALHOS FUTUROS

Através da investigação realizada neste trabalho, o emprego de redes neurais artificiais foi validado para a detecção da ocupação espectral.

O modelo U-Net adaptado mostrou-se bastante eficaz e eficiente para a tarefa de classificação semântica espectral, sendo demonstrado inclusive pelo autor original que é possível sua utilização em tempo real através de aceleração computacional usando GPU.

A técnica avaliada para a geração de amostras de ocupação espectral mostrou que apesar de ser bastante simplificada, é flexível e versátil o suficiente para ser estendida e cumprir a finalidade de simulação com bastante controle sobre o processo.

Foram levantadas diversas possibilidades para trabalhos futuros, algumas delas previstas inicialmente como escopo deste trabalho, mas que por limitações de tempo, não puderam ser executadas.

Entre elas, destacam-se:

- Aplicação de Modelos de Markov Escondidos (HMM) para modelagem temporal e predição do uso do espectro utilizando como observações as informações da classificação realizada pela RNA;
- Embarque de informação temporal no modelo U-Net para avaliação de seu desempenho na predição de uso do espectro;
- Investigação e avaliação do emprego de outras RNA na modelagem temporal e predição do uso do espectro em substituição aos Modelos Markovianos;
- Investigação e avaliação do desempenho de Redes Neurais Generativas para a geração de amostras de ocupação espectral com a finalidade de simulação;
- Simulação da ocupação oportunística secundária do espectro e comparação do desempenho com outros trabalhos.

REFERÊNCIAS

- [1] J. Mitola and G. Q. Maguire, "Cognitive radio: making software radios more personal," *IEEE Personal Communications*, vol. 6, no. 4, pp. 13–18, Aug 1999.
- [2] Y. Arjouni and N. Kaabouch, "A comprehensive survey on spectrum sensing in cognitive radio networks: Recent advances, new challenges, and future research directions," *Sensors*, vol. 19, no. 1, 2019. [Online]. Available: <https://www.mdpi.com/1424-8220/19/1/126>
- [3] C. Zhang, C. Zhang, S. Zheng, Y. Qiao, C. Li, M. Zhang, S. K. Dam, C. M. Thwal, Y. L. Tun, L. L. Huy, D. kim, S.-H. Bae, L.-H. Lee, Y. Yang, H. T. Shen, I. S. Kweon, and C. S. Hong, "A complete survey on generative ai (aigc): Is chatgpt from gpt-4 to gpt-5 all you need?" 2023.
- [4] A. Garza and M. Mergenthaler-Canseco, "Timegpt-1," 2023.
- [5] J. Gao, X. Yi, C. Zhong, X. Chen, and Z. Zhang, "Deep learning for spectrum sensing," *IEEE Wireless Communications Letters*, vol. 8, no. 6, pp. 1727–1730, 2019.
- [6] L. R. L. Rodrigues and E. L. Pinto, "Hmm models and estimation algorithms for real-time predictive spectrum sensing and cognitive usage," *XXXV SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES E PROCESSAMENTO DE SINAIS - SBR/T 2017*, 2017.
- [7] D. Liu, A. Honoré, S. Chatterjee, and L. K. Rasmussen, "Powering hidden markov model by neural network based generative models," 2020.
- [8] M. Mirza and S. Osindero, "Conditional generative adversarial nets," 2014.
- [9] A. Radford, L. Metz, and S. Chintala, "Unsupervised representation learning with deep convolutional generative adversarial networks," 2016.
- [10] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," 2022.
- [11] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," 2020.
- [12] Y. Xu, T. Gu, W. Chen, and C. Chen, "Ootdiffusion: Outfitting fusion based latent diffusion for controllable virtual try-on," 2024.
- [13] Z. Chen, Y. Wang, F. Wang, Z. Wang, and H. Liu, "V3d: Video diffusion models are effective 3d generators," 2024.
- [14] "Denoising Diffusion-based Generative Modeling: Foundations and Applications — cvpr2022-tutorial-diffusion-models.github.io," <https://cvpr2022-tutorial-diffusion-models.github.io/>, [Accessed 15-04-2024].
- [15] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," 2015.
- [16] D. Uvaydov, M. Zhang, C. P. Robinson, S. D'Oro, T. Melodia, and F. Restuccia, "Stitching the spectrum: Semantic spectrum segmentation with wideband signal stitching," 2024. [Online]. Available: <https://arxiv.org/abs/2402.03465>
- [17] F. Castellani, "Kiwibsb1 ya30(t2fd) antenna over 4g link brasil / br," <http://kiwibsb1.proxy.kiwisdr.com:8073/>, [Accessed 15-04-2024].