

Sensoriamento Espectral e Simulação de Ocupação de Espectro Utilizando Redes Neurais Artificiais - Proposta

Luiz Renault Leite Rodrigues
Instituto Nacional de
Telecomunicações (INATEL)
Santa Rita do Sapucaí, MG 37540-000
Email: luiz.rodrigues@dtel.inatel.br

Abstract

Este documento tem como objetivo apresentar a proposta da pesquisa pretendida para o projeto final da disciplina TP-558 no contexto do curso de Doutorado em Telecomunicações.

I. INTRODUÇÃO

A partir do surgimento do conceito de Rádio Cognitivo [1], tem sido investido grande esforço de pesquisa para viabilizar o uso por usuários secundários de faixas de frequências eventualmente ociosas, sem prejuízo do seu emprego pelos usuários licenciados em caráter primário.

O principal requisito para o uso compartilhado do espectro por um rádio cognitivo que opera em caráter secundário é, portanto, evitar interferência na operação do usuário primário. Com isso, torna-se fundamental para o rádio cognitivo secundário acompanhar a utilização de canais por outros usuários. Esta tarefa é realizada através do **sensoriamento espectral**.

Em áreas de aplicação sem grande exploração comercial como o setor de Segurança Pública, nota-se que muitas dos sistemas rádio utilizados são antigos e necessitam de atualização. Tem-se ainda como característica adicional a existência dos mais variados sistemas e padrões, adotados pelos diferentes órgãos existentes no país.

O rádio cognitivo se destaca neste contexto, podendo atender aos requisitos para modernização dos sistemas de telecomunicações. Um exemplo é o desenvolvimento de formas de onda de banda larga para comunicações militares em HF, com grande aplicabilidade no Rádio Definido por Software (RDS), projeto do Ministério da Defesa, e nas novas famílias de rádios desenvolvidas e fabricadas pela Indústria de Material Bélico do Brasil - IMBEL, vistos na FIG. 1.




Fig. 1. RDS Defesa (a), IMBEL TRC-1193V (b) TRC-1122 (c) e TPP-1400 (d).

O desenvolvimento das aplicações de software que rodam nestes rádios, chamadas Formas de Onda (FO), é um processo complexo e custoso, necessitando muitas vezes de centenas ou milhares de horas de trabalho para validação das implementações. Outra dificuldade observada é a escassa fonte de dados e de modelos de ocupação espectral, principalmente relacionado a aplicações mais restritas como as militares e de segurança pública. Com isso, torna-se extremamente relevante a capacidade de simulação de tais situações utilizando modelos com parâmetros ajustados a partir de dados coletados experimentalmente.

A abordagem clássica para o sensoriamento espectral e simulação de sistemas de comunicações baseia-se na abordagem estocástica [2], com diversas limitações.

Recentemente o uso de Redes Neurais Artificiais (RNA) tem crescido, se popularizado bastante e ganhado as mídias, como por exemplo as aplicações ChatGPT e *Stable Diffusion* [3]. Tais ferramentas permitem a geração de imagens computadorizadas

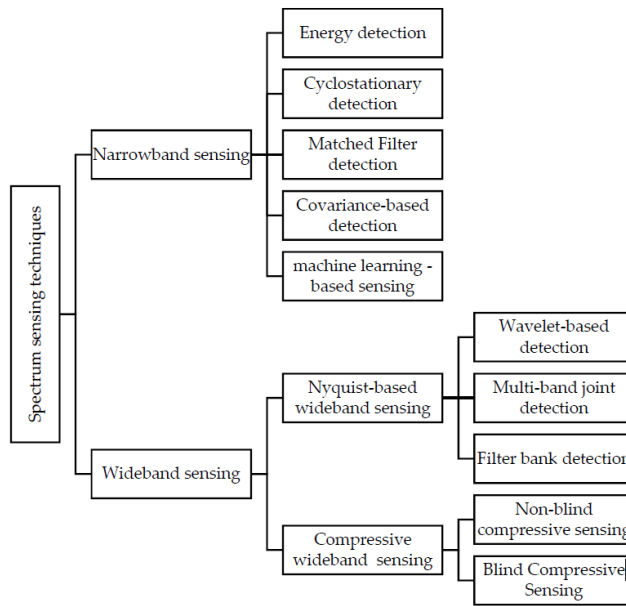


Fig. 2. Classificação de técnicas de sensoriamento espectral [2].

com elevado grau de realidade a partir de descrições textuais. Outras aplicações tem utilizado conceitos similares para a modelagem e síntese de dados no domínio do tempo, tendo como relevante exemplo a ferramenta TimeGPT [4], que permite a modelagem e predição de séries temporais usando RNA.

Algumas das vantagens do emprego de RNA são: capacidade de modelar complexidades não lineares, geração de dados realísticos, extrapolação em novos domínios, transferência de conhecimento / aprendizado, adaptabilidade a mudanças temporais, maior acurácia e eficiência em previsões e capacidade de lidar com grandes dados.

Dessa forma, cresce de importância a investigação de novas aplicações de RNA como substituição às abordagens clássicas para a solução de problemas associados ao sensoriamento espectral e simulação de sistemas de comunicações.

Assim, este trabalho terá por objetivo realizar pesquisa e experimentações sobre o emprego de Redes Neurais Artificiais e Aprendizado de Máquina para a modelagem de uso do espectro eletromagnético e a partir dela realizar a simulação da ocupação espectral para o uso no desenvolvimento de Formas de Onda.

II. TRABALHOS RELACIONADOS

A tecnologia associada a rádios cognitivos já vem sendo pesquisada há mais de duas décadas e evoluiu bastante nos últimos anos. Para ajudar pesquisadores a se situarem nos avanços obtidos na temática sensoriamento espectral, [2] trás um resumo das principais técnicas e as classifica de acordo com a FIG. 2.

Tais técnicas são divididas principalmente em sensoriamento de banda estreita, ou *narrowband sensing*, e sensoriamento de banda larga, ou *wideband sensing*. O primeiro consiste na análise de um único canal de radiofrequência, enquanto o segundo analisa um conjunto de canais.

Dentre os métodos empregados para o sensoriamento de banda estreita estão o de detecção de energia, detecção ciclostacionária, sensoriamento com filtro casado, detecção baseada em covariância, e sensoriamento baseado em aprendizado de máquina, este último o de interesse deste trabalho.

O sensoriamento de banda larga pode ser subdividido em outras duas sub-categorias: baseada em Nyquist e compressiva. Exemplos de métodos da primeira sub-categoria são a detecção baseada em *Wavelet*, a detecção conjunta multi-banda e a detecção empregando bancos de filtros. Dentre os métodos compressivos estão os de sensoriamento cegos e os não-cegos, classificados de acordo com o a necessidade de conhecimento *a priori* da esparsidade dos canais senseados.

Detalhes sobre cada um destes métodos podem ser encontrados em [2] e suas referências. Dentre os onze métodos que utilizam aprendizado de máquina citados na publicação, nenhum deles cita ser capaz de gerar amostras realistas de ocupação espectral de banda estreita ou larga para uso em simulações de sistemas de rádios cognitivos, possuindo como foco principal a detecção (cooperativa ou individual) [5] da ocupação ou de ataques cibernéticos relacionados ao sensoriamento espectral.

Em [6] este proponente mostra o emprego de Modelos de Markov Escodidos Não Estacionários (NS-HMM) e Modelos Bivariados de Markov Escondidos (HBMM) na detecção e predição de ocupação espectral aplicados a dados reais obtidos durante as Olimpíadas e Paraolimpíadas Rio 2016. Tais modelos, após terem seus parâmetros estimados a partir de uma

sequência de treinamento ou emprego adaptativo servem não só para estimar em tempo real a ocupação do espectro em banda estreita e prever a duração do estado de ocupação dado o estado atual, como também para produzir amostras simuladas com características estatísticas similares às dos dados reais modelados. Além disso, seu uso é estendido para sensoriamento de banda larga aplicando o modelo em múltiplos canais, obtendo bom desempenho ao óbice do aumento considerável do custo computacional.

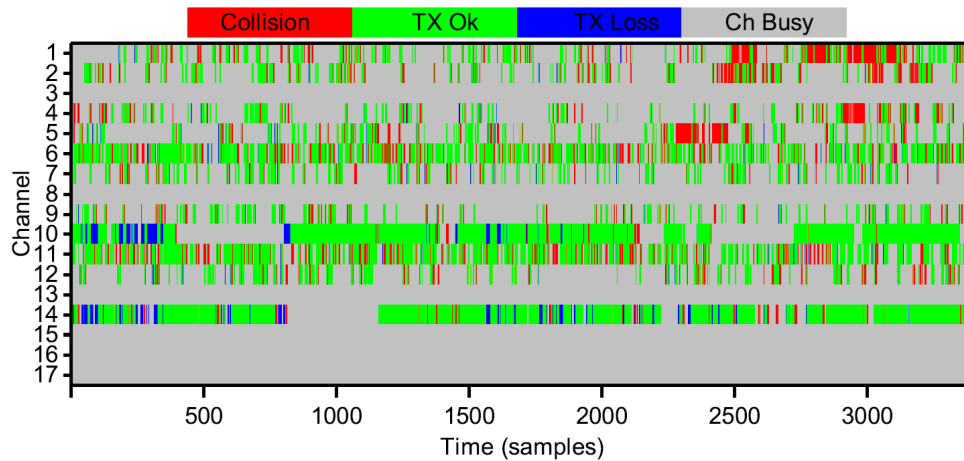


Fig. 3. Resultado do emprego de modelos NS-HMM em simulação de ocupação secundária de canais de RF [6].

A figura 3 mostra o resultado da simulação do uso secundário de canais de RF usando o modelo NS-HMM para detecção e predição do uso do espectro, onde são indicados os eventos de colisão, quando o usuário secundário transmite durante um canal ocupado pelo usuário primário, sucesso, quando o usuário secundário transmite com o canal livre, a perda de oportunidades de transmissão e os períodos corretamente preditos como canal ocupado.

A extensão da aplicação dos NS-HMM e HBMM para sensoriamento espectral de banda larga, apesar de eficaz é ineficiente no sentido de que cada modelo é aplicado individualmente a um canal, não fazendo uso por exemplo de informações da relação estatística do uso de canais adjacentes. Além disso, o custo computacional é multiplicado pelo número de canais sensoriados, tornando-se não prático para diversas aplicações embarcadas de tempo real.

O uso de redes neurais generativas (RNG) para melhoria de modelos baseados em Modelos de Markov Escondidos pode ser encontrado em [7].

Redes neurais generativas funcionam, de uma forma bastante resumida, usando modelos de RNA para através de treinamento prévio aprender uma distribuição estatística latente presente em dados de referência, condicionados a características destes dados, e após, apresentadas características escolhidas, gerar outros dados realistas de acordo com as distribuições aprendidas.

Recentemente, novas arquiteturas de RNA e o aumento da capacidade computacional aplicada ao processamento de RNA popularizaram bastante o emprego de redes neurais generativas em aplicações como síntese de imagens realistas, geração de textos coerentes, geração de fala replicando vozes reais, e diversas outras. Dentre as arquiteturas de RNG destacam-se as Redes Generativas Adversárias [8], [9], os Auto Codificadores Variacionais (VAE) [10] e as baseadas em Modelos de Difusão (DM) [11]–[13]. Detalhes das arquiteturas e de implementação podem ser vistos em suas respectivas publicações.

De particular interesse nesta proposta, as redes baseadas em Modelos de Difusão possuem este nome pois baseiam-se no fenômeno físico da difusão, onde ruído é adicionado a um conjunto de dados de interesse, gerando amostras dos dados ruidosas, como se o próprio ruído fosse difundido. Durante o treinamento da rede, "observando" o processo gradual de difusão até a completa corrupção dos dados originais, a rede é capaz de "aprender" como realizar o processo inverso e estimar dados puros a partir de amostras ruidosas. Isso faz com que a rede incorpore uma distribuição estatística que representa o universo de dados apresentados no treinamento e ao receber uma amostra de ruído puro, realiza o processo gradual de eliminação do ruído até gerar uma amostra de dados que represente esta estatística.

Uma aplicação comum dos Modelos de Difusão é a geração de imagens realistas. Um exemplo do processo reverso difusão e geração de imagem pode ser visto na figura 4. O dado puro é a imagem do gato à esquerda e o dado completamente corrompido é a imagem da direita, apenas com ruído. O processo de difusão direta é indicado da esquerda para a direita, enquanto o processo de geração é indicado pela seta da direita para a esquerda. Mais detalhes desta arquitetura e seu funcionamento podem ser obtidos em [11].

Uma característica interessante dos Modelos de Difusão é que sua implementação é baseada em um outro modelo (Rede em U ou U-Net) empregado com destaque na segmentação e classificação semântica de dados ou imagens. Detalhes do modelo

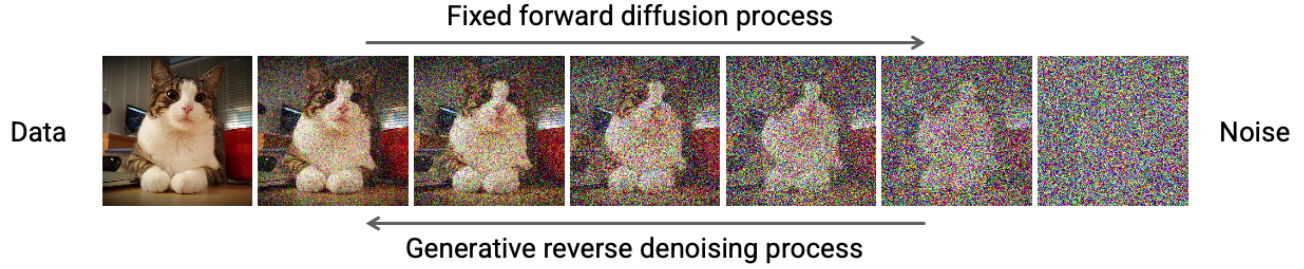


Fig. 4. Ilustração do princípio de funcionamento das RNG baseada em Modelos de Difusão [14].

U-Net são descritos em [15], e a sua adaptação para uma rede generativa em [11].

Ressalta-se que os trabalhos citados acima não representam todo o conjunto de métodos e técnicas relacionadas ao sensoriamento espectral ou a redes neurais generativas, mas o mínimo suficiente para o encadeamento das seções subsequentes, onde será formalizado o problema proposto para investigação, descritos a hipótese de levantada para a solução deste problema, a metodologia utilizada para testar se a solução é eficaz e os resultados esperados.

III. DESCRIÇÃO DO PROBLEMA

O problema proposto a ser tratado neste projeto é o sensoriamento espectral de banda larga com o objetivo de detectar o uso do espectro de radiofrequência (sub-problema i), realizar previsões sobre o uso futuro baseado no estado presente e passado (sub-problema ii), e a geração (simulação) de amostras de ocupação espectral utilizando um modelo treinado empregando amostras reais de uso do espectro que representem estatisticamente estes dados (sub-problema iii).

A figura 5 mostra a tela de uma aplicação baseada em rádio definido por software (SDR) disponível publicamente na internet, onde é possível visualizar o espectrograma de um sinal de radiofrequência capturado por uma estação localizada na cidade de Brasília-DF. O eixo horizontal representa frequências entre 23 MHz (à esquerda) e 30 MHz (à direita), enquanto o eixo vertical representa o tempo, sendo as amostras mais recentes as superiores, e as amostras inferiores as capturas dezenas de segundos antes. A codificação de cores da imagem representa a magnitude do sinal recebido, com potências baixas representada pela cor preta e azul escuro, médias pela ciano, até as mais elevadas pela coloração vermelha.

Dessa forma, pode-se concluir que há usuários utilizando o espectro nos instantes em que a cor dos pixels se difere da cor de fundo (azul ou preto).

Assim, para fazer o uso secundário ou oportunista do espectro, um rádio cognitivo deveria apenas transmitir nos casos em que não há outros usuários transmitindo, de forma a evitar infringir ou sofrer interferências.

Para tal, é necessário que o rádio cognitivo (RC) possa inferir sobre o estado de ocupação de uma determinada faixa de frequência e sobre o tempo que esta faixa ficará disponível para seu uso. Esta atividade torna-se extremamente difícil caso o RC não possua informações prévias sobre como os outros usuários utilizam o espectro, o que é muito comum em aplicações práticas.

Além disso, torna-se fundamental para o desenvolvimento de aplicações para rádios cognitivos a capacidade de simular ambientes realistas produzindo cenários similares aos vistos na figura, no qual algoritmos cognitivos possam ser testados.

O diagrama de blocos da FIG. 6 ilustra processo do sensoriamento e detecção da presença do usuário primário. O sinal recebido $r(t)$ corresponde ao sinal transmitido por um sistema primário, alterado pelo canal e pelo ruído aditivo $n(t)$.

Nos algoritmos de detecção de energia para sensoriamento de banda estreita, a modelagem estatística da ocupação do canal compreende a definição de duas hipóteses dadas por:

$$r(t) = \begin{cases} n(t), & \text{Hipótese } H_1: \text{ não há outro sinal de rádio presente} \\ p(t) + n(t), & \text{Hipótese } H_2: \text{ há outro sinal de rádio presente.} \end{cases}$$

Com isso, define-se o **estado de ocupação** do canal s , onde $s = 1$ significa que a primeira hipótese é verdadeira e não há ocupação do canal, assim como $s = 2$ indica a ocupação do canal pelo usuário primário¹.

No caso do sensoriamento de banda larga, como na figura 5, $r(t)$ será substituído por $r(t, f)$ onde f é a frequência.

¹ Apesar do processo de detecção estar exemplificado com apenas 2 estados, um número maior de estados pode ser utilizado.

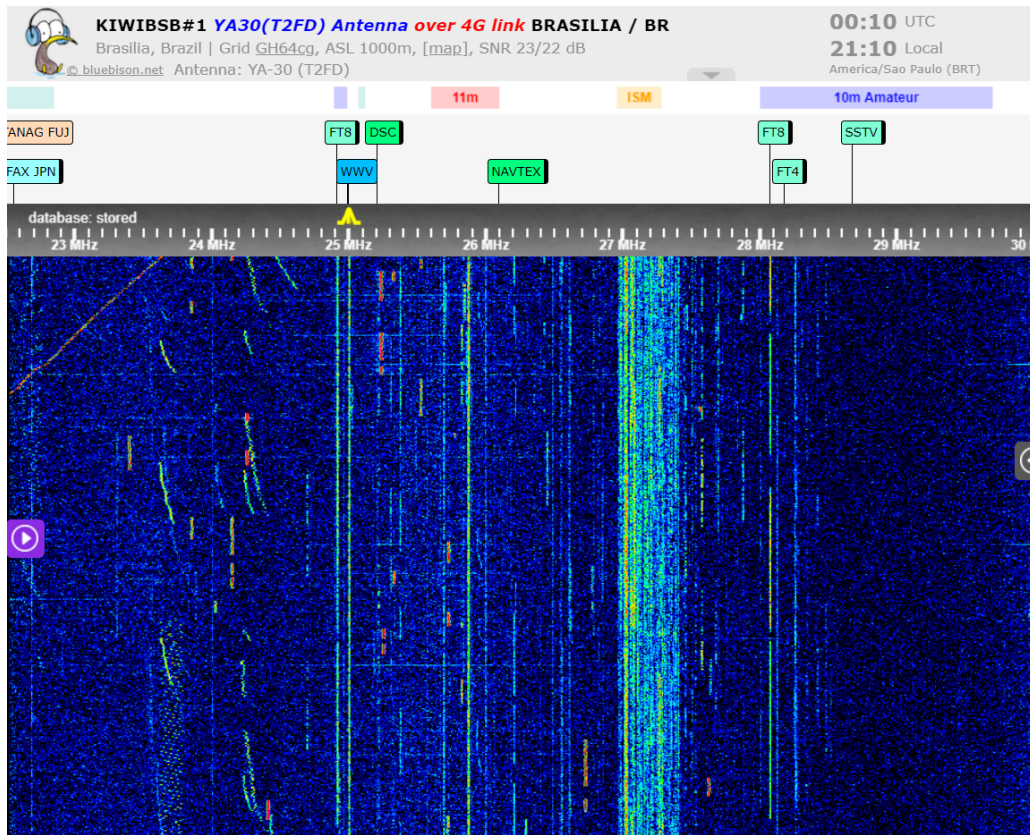


Fig. 5. Exemplo de espectrograma obtido por um rádio definido por software [16].




Fig. 6. Diagrama de blocos do processo de sensoriamento espectral.

Na etapa de sensoriamento são realizadas as operações de recepção, filtragem, seleção de faixa ou canal, amostragem e conversão analógica digital. Os sinais digitalizados, normalmente expressos pelas suas componentes em fase e quadratura (I e Q) em banda base, podem ser pré-processados antes de serem apresentados ao detector, dando origem às estatísticas utilizadas no processo de detecção.

Dessa forma, os dados referência para os modelos podem ser repassados tanto no domínio do tempo, através das amostras complexas I e Q, no domínio da frequência, obtidos através da Transformada de Fourier do sinal, de representações estatísticas do sinal ou qualquer outra transformação do sinal capturado.

As saídas do modelo poderão ser de qualquer formato que represente os estados de ocupação definidos e / ou o sinal estimado no domínio do tempo, da frequência, ou qualquer transformação que solucione os sub-problemas i, ii ou iii.

O objetivo do emprego do modelo é realizar a transmissão (simulada) oportunista de maneira que não haja interferência entre o transmissor cognitivo e os demais usuários.

IV. SOLUÇÃO PROPOSTA

Propõe-se utilizar redes neurais generativas para aprenderem a distribuição latente da ocupação espectral em uma determinada faixa do espectro de radiofrequência e ser capaz de inferir sobre a ocupação e gerar amostras realistas da ocupação espectral para fins de simulação.

Particularmente será investigado o emprego dos Modelos de Difusão para a solução do sub-problema ii e iii e de U-Net para a solução do problema i.

Os modelos poderão ser utilizados tendo como dados de treinamento as imagens bidimensionais coloridas de espectrogramas de forma similar às aplicações das publicações originais de ambos os modelos. As saídas esperadas de cada modelo para este

caso de aplicação são imagens de espectrogramas sintetizados para o caso do Modelo de Difusão e imagens segmentadas com classes definidas para a ocupação espectral, no caso do U-Net. Os dois modelos poderão ser usados em sequência para a partir de uma estimativa de espectrograma gerada pelo DM seja feita a segmentação pela U-Net que será utilizada para a decisão de uso secundário do espectro.

Em uma aplicação um pouco distinta das originalmente propostas, os modelos poderão ser avaliados utilizando como dados de referência vetores unidimensionais representando amostras complexas no domínio do tempo, ao invés de imagens de espectrogramas. Para tal são necessárias algumas adaptações nos modelos, principalmente relacionadas à dimensão dos dados de entrada e saída e dimensão dos filtros utilizados.

Serão investigadas também outras representações que possam levar a melhores resultados na solução do problema.

Outros modelos ou adaptações desde dois modelos poderão ser investigados durante a execução do projeto.

V. METODOLOGIA

Os modelos investigados deverão ser aplicados de maneira que os resultados produzidos possam ser expressos como na figura 3, permitindo a comparação de desempenho entre os modelos investigados baseados em RNG e o referenciado naquela publicação.

Para isso, poderão ser utilizados os mesmos dados capturados em [6], ainda em posse deste proponente, ou novos dados, desde que sejam também avaliados utilizando os modelos propostos naquela publicação.

A investigação da solução proposta abrangerá, mas não se limitará a:

- 1) Obtenção de implementações de referência das arquiteturas de RNA a serem empregadas;
- 2) Validação das implementações utilizando dados de referência que permitam a comprovação do funcionamento do modelo;
- 3) Tratamento dos sinais capturados em [6] para geração de dados de referência para aplicação dos modelos de RNA;
- 4) Complementação manual dos dados tratados para produzir uma classificação de referência para a ocupação do espectro;
- 5) Separação dos dados tratados e da classificação de referência em dois grupos: de treinamento e de avaliação;
- 6) Utilização dos dados tratados e da classificação de referência reservada para treinamento para treinar os modelos de RNA;
- 7) Aplicação das RNA nos dados de avaliação e gerar as métricas de desempenho;
- 8) Analisar as métricas de desempenho e refazer qualquer um dos passos de forma o melhorá-lo;
- 9) Elaboração de relatório sobre a investigação e seus resultados, incluindo comparações de desempenho com outras técnicas.

A descrição e detalhamento do problema e a solução proposta poderão ser refinadas durante a execução da pesquisa, mantendo a premissa de permitir a avaliação do emprego da temática investigada e a comparação com outros métodos.

VI. RESULTADOS ESPERADOS

Espera-se que as RNA sejam capazes de representar características estatísticas similares aos dos Modelos de Markov Escondidos e suas variantes, como sugerido em [7], ou mesmo ampliando a capacidade de modelagem.

Uma das características evidenciadas pelos autores do modelo U-Net é a adequação do modelo à identificação de instâncias de classes justapostas e com bordas pouco definidas. Tal característica aplicada ao sensoriamento espectral pode ser de grande aplicabilidade na determinação dos limites temporais e espectrais de um evento de ocupação de canal.

Espera-se que após os ajustes dos modelos investigados o desempenho no sensoriamento espectral com o objetivo de reduzir interferência entre o usuário cognitivo e os demais seja superior ao das técnicas tradicionais, ou que sejam apresentadas sugestões de investigações adicionais que possam levar a resultados ainda melhores.

REFERENCES

- [1] J. Mitola and G. Q. Maguire, "Cognitive radio: making software radios more personal," *IEEE Personal Communications*, vol. 6, no. 4, pp. 13–18, Aug 1999.
- [2] Y. Arjouni and N. Kaabouch, "A comprehensive survey on spectrum sensing in cognitive radio networks: Recent advances, new challenges, and future research directions," *Sensors*, vol. 19, no. 1, 2019. [Online]. Available: <https://www.mdpi.com/1424-8220/19/1/126>
- [3] C. Zhang, C. Zhang, S. Zheng, Y. Qiao, C. Li, M. Zhang, S. K. Dam, C. M. Thwal, Y. L. Tun, L. L. Huy, D. Kim, S.-H. Bae, L.-H. Lee, Y. Yang, H. T. Shen, I. S. Kweon, and C. S. Hong, "A complete survey on generative ai (aigc): Is chatgpt from gpt-4 to gpt-5 all you need?" 2023.
- [4] A. Garza and M. Mergenthaler-Canseco, "Timegpt-1," 2023.
- [5] J. Gao, X. Yi, C. Zhong, X. Chen, and Z. Zhang, "Deep learning for spectrum sensing," *IEEE Wireless Communications Letters*, vol. 8, no. 6, pp. 1727–1730, 2019.
- [6] L. R. L. Rodrigues and E. L. Pinto, "Hmm models and estimation algorithms for real-time predictive spectrum sensing and cognitive usage," *XXXV SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES E PROCESSAMENTO DE SINAIS - SB/T 2017*, 2017.
- [7] D. Liu, A. Honoré, S. Chatterjee, and L. K. Rasmussen, "Powering hidden markov model by neural network based generative models," 2020.
- [8] M. Mirza and S. Osindero, "Conditional generative adversarial nets," 2014.
- [9] A. Radford, L. Metz, and S. Chintala, "Unsupervised representation learning with deep convolutional generative adversarial networks," 2016.
- [10] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," 2022.
- [11] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," 2020.
- [12] Y. Xu, T. Gu, W. Chen, and C. Chen, "Ootdiffusion: Outfitting fusion based latent diffusion for controllable virtual try-on," 2024.
- [13] Z. Chen, Y. Wang, F. Wang, Z. Wang, and H. Liu, "V3d: Video diffusion models are effective 3d generators," 2024.

- [14] “Denoising Diffusion-based Generative Modeling: Foundations and Applications — cvpr2022-tutorial-diffusion-models.github.io,” <https://cvpr2022-tutorial-diffusion-models.github.io/>, [Accessed 15-04-2024].
- [15] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” 2015.
- [16] F. Castellani, “Kiwibsb1 ya30(t2fd) antenna over 4g link brasilia / br,” <http://kiwibsb1.proxy.kiwisdr.com:8073/>, [Accessed 15-04-2024].